Sistemas Operacionais Laboratorio 1 - System Calls

Adaptação do Laboratório 1 - Prof. Eduardo Zambon & Prof. Roberta L. Gomes

1 System Calls no Linux

Vamos mencionar aqui alguns pontos já discutidos em aula e introduzir novos conceitos e informações úteis.

1.1 Aonde fica o kernel do SO?

Na maioria dos sistemas operacionais, o kernel é carregado no espaço de endereçamento virtual de todos os programas em execução. Por exemplo, o Linux em uma arquitetura x86 32-bits é mapeado no gigabyte (GB) mais "alto" do espaço de endereçamento, começando no endereço 0xf0000000.

Note que o espaço de endereçamento virtual de um processador 32-bits é $2^{32} = 4$ GB, o que leva a um espaço de endereçamento virtual efetivo de 3 GB para a aplicação em si e 1 GB para o kernel.

Então como o kernel evita que uma aplicação reescreva as estruturas do kernel ou chame as funções do kernel diretamente? Isso é tarefa do mecanismo de mapeamento de memória, que permite ao SO especificar em qual ring a CPU deve estar executando para poder acessar uma dada região de memória.

1.2 Protection rings

A CPU x86 possui quatro rings, ou níveis de privilégio. Entretanto, a maioria dos OSes usa somente dois rings: ring 0 (kernel mode) e ring 3 (user mode). Os rings de numeração mais alta são mais restritos, indicando que eles não podem executar certas instruções privilegiadas, tais como instruções que vão interagir diretamente com o hardware. De forma similar, os mecanismos de proteção de endereços de memória (mais precisamente, páginas de memória, mas estudaremos isso um pouco mais adiante no curso) conseguem diferenciar permissões de acesso dependendo do ring atual em que a CPU está executando.

1.3 Trocando de rings

Como a CPU sai de um ring para outro?

Em geral, uma vez que a CPU entrou no ring 3 (user mode), o único jeito de retornar ao kernel mode é por meio de uma interrupção. Uma interrupção pode ser um evento de hardware, tal como um disco sinalizando a conclusão de uma operação de leitura/escrita; ou pode ser também uma interrupção de software (a famosa chamada de sistema ou System Call), em que o software intencionalmente levanta uma interrupção usando uma instrução especial. Por fim existe um terceiro tipo de interrupção (que pode ser entendida como de hardware... mas não há consenso sobre essa definição) chamada de exceção, como no caso de uma divisão por zero. O Termo trap também é muito usado na literatura ou pela comunidade, mas não há consenso sobre a terminologia (alguns definem trap como sendo as Syscalls, enquanto outros como sendo

qualquer interrupção que cause desvio para o Kernel). A figura 1 apresenta uma terminologia bem aceita pela comunidade acadèmica (Cornell Unitersity¹):




Figura 1: Uma terminologia bastante aceita.

Na arquitetura x86, interrupções são associadas com um valor 8-bits específico. Por exemplo, a exceção de divisão por zero recebe o número de interrupção 0. Este valor serve como um índice na interrupt descriptor table (IDT), onde o kernel "instala" um handler (função) que é chamado quando uma interrupção dispara.

A IDT também especifica em qual *ring* o *handler* deve executar; em geral, o *ring* é zero. Assim, qualquer *software* que pode causar alguma interrupção vai levar a CPU a trocar para o *ring* zero e começar a executar o *handler* específico.

Alguns números de interrupção são designados pelo desenvolvedor do hardware. A Intel reserva as interrupções 0–31 para exceções, e por convenção, as 16 seguintes são tipicamente utilizadas para interrupções de dispositivos. Os outros 212 códigos de interrupção restantes ficam sob controle do kernel. O uso mais comum de um handler de interrupções é tratar as System Calls de uma aplicação. Por exemplo, o Linux utiliza 0x80, ou 128 em decimal, para a sua interrupção de System Call. O Windows, por outro lado, utiliza 0x2e, ou 46 em decimal. Essa escolha é totalmente arbitrária.

E como isso fica no código? Se você fizer um disassemble de um binário 32-bits antigo que faz uma chamada de sistema, você deve ver uma linha contendo int \$0x80. A instrução int gera uma interrupção de software que leva a um salto (desvio) na execução para a função especificada como o handler da interrupção 0x80, que roda no ring 0. Antes que o salto seja realizado, alguns registradores são salvos na pilha. Durante a execução do handler da interrupção 0x80, o SO procura na Syscall Table o endereço da chamada de sistema em si que deve ser executada (usando o código que foi passado no EAX), gerando um novo desvio para a função que implementa a chamada de sistema. Após a execução da chamada de sistema, o kernel retorna o controle para a aplicação por meio da instrução iret, que restaura os registradores da aplicação e retorna para ring 3. A figura 2 resume os passos executados durante uma Syscall no Linux 32-bits.

Importante: int \$0x80 é um código legado e deve ser evitado, pois não está mais disponível em CPUs 64-bits (ele só foi utilizado como um exemplo!). O método atual de entrar em kernel mode em arquiteturas x86 64-bits é com a instrução syscall.

¹http://www.cs.cornell.edu/courses/cs3410/2012sp/lecture/22-traps-i-g.pdf

1. Software executes int 0x80 Pushes EIP, CS, and EFLAGS Main Memory 2. CPU transfers execution to the OS handler OS Code Look up the handler in the IDT printf() Switch from ring 3 to 0 3. OS executes the system call 0x80 Handler Syscall Table Save the processes state Use EAX to locate the system call Execute the system call Restore the processes state Put the return value in EAX 4. Return to the process with iret Pops EIP, CS, and EFLAGS

Figura 2: Passos executados durante uma Syscall no Linux 32-bits

2 Códigos de Exemplos de System Calls

Switches from ring 0 to 3

O programa abaixo é o exemplo clássico de Hello World implementado em C.

```
int main(void) {
  printf("Hello World!\n");
  return 0;
}
```

Esse programa faz uso da função printf que está definida em stdio.h. Esse arquivo define as funções de I/O que estão implementadas na biblioteca padrão do C (libc). Para um usuário normal, essa biblioteca provê a interface com as funcionalidades do SO.

Descendo um nível na API, é possível ver que as funções em stdio.h utilizam outras funções de mais baixo nível, as chamadas system call wrappers, que são funções que preparam a chamada da system call real. O programa abaixo utiliza os wrappers para reimplementar o programa de Hello World, empregando somente a função write, que faz parte do padrão POSIX, definido em unistd.h.

```
#include <unistd.h>
int main(void) {
    const char *msg = "Hello World!\n";
    write(STDOUT_FILENO, msg, 13);
    return 0;
}
```

Baixando mais ainda o nível, é possível realizar diretamente as *system calls* do *kernel*, mas para tal é preciso programar diretamente no *assembly* da arquitetura, como ilustrado no programa a seguir.

```
9
            .global _start
10
            .text
11
    start:
12
            # write(1, message, 13)
13
            mov $1, %rax
                                       # system call 1 is write
14
            mov $1, %rdi
                                        file handle 1 is stdout
15
            mov $message, %rsi
                                         address of string to output
16
            mov $13, %rdx
                                        number of bytes
17
            syscall
                                        invoke operating system to do write
18
19
            # exit(0)
20
            mov $60, %rax
21
                                         system call 60 is exit
            xor %rdi, %rdi
                                         we want return code 0
22
            syscall
                                         invoke operating system to exit
23
24
   message:
            .ascii "Hello World!\n"}
```

O programa acima está escrito em Assembly x86_64, no padrão AT&T, que é o utilizado pelo as, o montador do gcc. A system call que escreve no terminal é invocada pelo comando syscall. Esse comando não possui operandos pois cada system call tem um número variável de argumentos. Esses argumentos são passados em registradores, que precisam ser preenchidos corretamente antes da chamada. O registrador rax sempre deve conter o código da system call que deve ser executada. Os demais registradores variam conforme esse código. Uma tabela completa de todas as system calls do Linux 64-bits (com os respectivos registradores) pode ser vista em http://blog.rchapman.org/posts/Linux_System_Call_Table_for_x86_64/.

3 Chamada fork()

Agora que você já tem uma visão geral de como as *Syscalls* funcionam, vamos estudar algumas *Syscalls* importantes para a criação e gerência de processos. A primeira delas é o fork()!

O fork() é usado para criar um novo processo em sistemas do tipo Unix. Quando criamos um processo por meio do fork(), dizemos que esse novo processo é o filho, e processo pai é aquele que chamou o fork().




Figura 3: Processo A é o pai dos Processos B e C.

Quando o fork() for usado, será criado o processo filho, que será idêntico ao pai (uma cópia do pai!), inclusive tendo mesmo código, mesmas variáveis (e valores!), ponteiros para arquivos abertos, etc. Ou seja, o processo filho é uma cópia do pai, "exatamente" igual. As

aspas aqui devem-se ao seguinte: na verdade não será exatamente igual... algumas informações de controle (presentes no bloco de controle do proecesso filho) serão diferentes... como o caso do PID ou do PPID (parent PID).




Figura 4: O processo filho é uma cópia do processo pai.

Como isso o processo filho tem **seu próprio espaço de endereçamento**, com cópia de todas as variáveis do processo pai (lembrem-se que elas ficam armazenadas no segmento de dados ou na pilha). Essas são independentes em relação às variáveis do processo pai. Além das variáveis (globais e locais), o processo filho "herda" do pai alguns atributos, tais como: variáveis de ambiente, privilégios e prioridade de escalonamento. O processo filho também herda alguns recursos, tais como arquivos abertos e devices. No entanto, alguns atributos e recursos, tais como PID, PPDI, sinais pendentes e estatísticas do processo, não são herdados pelo processo filho. A figura 4 ilustra os espaços de endereçamento do processo pai e filho. Observem na figura que o segmento de código (*Text*) não precisa ser copiado... o mesmo pode ser compartilhado entre os dois processos, uma vez que esse é *read-only*.

Copy-on-Write

Como alternativa à significante ineficiência do fork(), no Linux o fork() é implementado usando uma técnica chamada **copy-on-write** (COW). Essa técnica atrasa ou evita a cópia dos dados. Quando um processo filho é criado, ao invés de copiar o espaço de endereçamento do processo pai, ambos podem compartilhar uma única cópia somente de leitura. Se uma escrita é feita (seja pelo pai ou pelo filho), uma duplicação do seguimento é realizada imediatamente antes da escrita ser efetivada, e cada processo recebe sua própria cópia do seguimento. Consequentemente, a duplicação é feita apenas quando necessário, economizando tempo e espaço. Assim, o único overhead inicial do fork() é a duplicação das tabelas de gerência de memória (pai -> filho) e a criação de um novo bloco de controle de processo (BCP) para o filho.

Voltando à figura 3, vocês podem observar outra chamada de sistema: a chamada wait(). A sincronização entre processo pai e filho(s) é feita por meio da Syscall wait(), que bloqueia o processo pai até que um processo filho termine (mas veremos isso melhor mais tarde, em outro laboratório).

Agora vamos a algumas notas sobre a chamada fork():

- A função fork() é invocada uma vez (no processo pai) mas retorna duas vezes quando há sucesso: uma no processo que a invocou e outra no novo processo criado, o processo filho.
- Em caso de sucesso da chamada, o valor de retorno da função fork() no processo pai é igual ao número do PID do processo filho recém criado (lembrando que todos os processos em Unix têm um identificador, geralmente designado por PID process identifier). Em caso de erro, a chamada retorna o valor -1 e nenhum processo filho é criado. Isso pode ocorrer, por exemplo, porque o usuário estourou o limite de processos que ele pode criar.
- Para o processo filho, o valor de retorno da função fork() é igual a 0 (zero).

Tarefas

- 1. Faça o download dos arquivos exemplos para a aula de hoje: lab1.zip
- 2. Execute o arquivo simple_fork.c, analise o código e observe as diferenças nos valores exibidos pelos processos pai e filho. Obs: as chamadas getpid() e getppid() imprimem o próprio PID do processo e o PID do processo pai, respectivamente.

4 Diferenciando "Processo Pai" do "Processo Filho"

Uma vez que processos pai e filho rodam o mesmo código (sim! é o mesmo arquivo executável!!), para permitir que após o fork() pai e filho possam executar instruções distintas, normalmente o código do programa é estruturado conforme mostrado na listagem a seguir. No código mostrado, notem que quando o processo filho for executar pela primeira vez, ele começará a rodar exatamente a partir da linha 2. O processo filho NÃO executa o código que antecede fork() no qual ele foi criado

Para entender melhor quais são as primeiras instruções (de máquina!) executadas pelo processo filho, teríamos que enxergar o código em assembly. A grosso modo, dentre outras coisas, é colocado no registrador EAX o valor de retorno 0. Em seguida, no caso do código mostrado, é feita uma cópia desse valor para a região de memória correspondente à variavel pid (pid=fork()).

```
1
       pid=fork();
2
       if(pid < 0) {
3
                /* falha do fork */
4
5
       else if (pid > 0) {
6
                /* codigo do pai */
8
       else { //pid == 0
9
                /* codigo do filho */
10
```

A figura 5 ilustra um exemplo de código usando fork(). As setas azuis indicam o instante logo após a execução do fork() em que os valores retornados pela função são atribuídos às variáveis pid (no pai e no filho). Observem que se a máquina possuir duas CPUs isso pode até ser executado simultaneamente. Mas se não for o caso, o escalonador é quem vai definir quem roda primeiro (pai ou filho).




Figura 5: O processo filho começa a rodar a partir da linha de código em que é feita a chamada fork() que o criou.

Tarefas

- 3. Agora vamos diferenciar Pai e Filho... Execute o arquivo two_procs.c e analise o código. Por que são exibidos valores distintos para a variável glob (pelo pai e pelo filho) se a variável é global?!? [Transcreva sua resposta no formulário online]
- 4. Cuidado ao dar nomes às variáveis do programa! Execute arquivo myPID.c, analise o código. A variável mypid está sendo exibida com o mesmo valor no pai e no filho... você não achou isso estranho?!? Por que isso ocorre?

5 User ID, Group ID e Process Group

No Unix, cada processo tem um proprietário, um usuário que seja considerado seu dono. Por meio das permissões fornecidas pelo dono, o sistema sabe quem pode e não pode executar o processo em questão. Para lidar com os donos, o Unix usa os números **UID** (*User Identifier*) e **GID** (*Group Identifier*). Os nomes dos usuários e dos grupos (de usuários) servem apenas para facilitar o uso humano do computador.

Cada usuário precisa pertencer a um ou mais grupos. Como cada processo (e cada arquivo) pertence a um usuário, logo esse processo pertence ao grupo de seu proprietário. Assim sendo, cada processo está associado a um UID e a um GID.

Os números UID e GID variam de 0 a 65536. Dependendo do sistema, o valor limite pode ser maior. No caso do usuário root, esses valores são sempre 0 (zero). Assim, para fazer com que um usuário tenha os mesmos privilégios que o root, é necessário que seu GID seja 0.

Outro conceito também definido pelo UNIX é o de *Grupo de Processos*. No UNIX, **por default**, um processo e todos os seus descendentes formam um grupo de processos (identificado pelo **PGID** - *Process Group ID*). Isso facilita a gerência dos processos (por exemplo, é possível

terminar um grupo inteiro de processos com apenas uma chamada de sistema). Além disso também facilita o compartilhamento de recursos. Quando um processo é criado, ele é colocado no mesmo process group de seu pai. Mas vale ressaltar que um processo, por meio de syscalls, pode se excluir de um grupo, migrando para um novo grupo ou para um grupo já existente (dentro da mesma session... mais sobre isso em breve!).

A seguir são listadas algumas chamadas de sistema para verificar/setar UID², GID e PGID:

```
//Chamadas para consultar o user:
1
       uid_t getuid(void) //UID
2
3
       uid_t geteuid(void)
                            //effective user id
4
  //Chamadas para consultar o user group:
5
       gid_t getgid(void)
                           //GID
       gid_t getegid(void) //effective group id
   //Chamada para consultar o process group
9
       pid_t getpgrp(void); //PGID
10
       //...ou
11
       pid_t getpgid(pid_t pid); //'0' como parametro retorna o PGID
12
                                 //do processo que executou a chamada
13
14
  //Chamada para alterar o process group
15
       int setpgid(pid_t pid, pid_t pgid);
16
                    // seta o valor do ID do grupo do processo
17
18
                    // (especificado por pid) para pgid */
```

Tarefas

- 5. Altere o arquivo two_procs.c de forma que tanto o pai quanto o filho imprimam os valores do *User ID* e do *Process Group ID*. O que você observou sobre o grupo de processos? Pai e filho estão no mesmo grupo? [Responda no formulário online]
- 6. Agora altere o código novamente de forma que o filho altere seu grupo de processo, criando um novo grupo cujo PGID será igual ao PID deste processo. *Dica:* man setpgid³

6 Relembrando: Comando PS

(Retirado de man ps) By default, ps selects all processes with the same effective user ID (euid=EUID) as the current user and associated with the same terminal as the invoker. It displays process ID (pid=PID), terminal associated with the process (tname=TTY), cumulated CPU time in [dd-]hh:mm:ss format (time=TIME), and the executable name (ucmd=CMD). Output is unsorted by default.

Opções interessantes:

²Na realidade, todo processo tem mais de um ID de usuário: além do *uid* (também é denominado *real uid*) há também o *effective uid*, ou *euid*. O *euid* é quem de fato define os direitos de acesso para um processo. Quando você faz o login, o shell de login define o *real uid* e *effective uid* com o mesmo valor (seu id de usuário real). Mas em algumas situações, dependendo do programa que um determinado processo executa, o *euid* pode ser alterado para outro usuário, geralmente o *root*. Com isso o processo passa a ter direto de acesso de root. Um exemplo famoso dessa funcionalidade é o comando *passwd*: quando o processo executa esse programa, ele passa a ter o *euid* setado para *root*, podendo com isso alterar o arquivo de senhas de usuários.

³O que foi pedido no exercício é simples... mas as regras para mudança de grupo de processo são bem complicadinhas. Caso tenha interesse, neste livro (sessão 10.6.3) você encontra mais informações.

- \$ ps Lista os processos do usuário associados ao terminal
- \$ ps 1 Idem, com informações mais completas
- \$ ps a Lista também os processos não associados ao terminal
- \$ ps u Lista processos do usuário
- \$ ps U <user> ou \$ps -u <user> Lista processos do usuário <user>
- \$ ps p <PID> Lista dados do processo PID
- \$ ps r Lista apenas os processos no estado running
- \$ ps f Mostra a árvore de execução dos processos
- \$ ps t Mostra todos os processos do terminal (incluindo a coluna STAT)
- \$ ps x Mostra todos processos do usuário
- \$ ps al, \$ ps au, \$ ps aux

Tarefas

7. Escreva um programa C que receba como parâmetro de entrada um inteiro N. Esse programa deve criar uma sequência de N filhos. Você deve usar a estrutura for(...). Em um outro terminal (Ctrl-Alt-t), use o comando \$ ps (e suas variantes) para exibir os processos que foram criados.

Dica: A chamada fork() deve aparecer dentro do loop... mas visto que após cada execução do fork() passamos a ter um processo pai e um filho, apenas o pai deve permanecer dentro do loop... o filho deve sair do loop assim que for criado.

8. Dado o código a seguir, quantos processos são criados (incluindo o processo principal) quando n=4? [Responda no formulário online]

```
#include <stdlib.h>
   #include <unistd.h>
2
3
  int main (int argc, char *argv[]) {
       pid_t childpid = 0;
5
       int i, n;
6
       /* check for valid number of command-line arguments */
       n = atoi(argv[1]);
8
       for (i = 1; i < n; i++)</pre>
9
           if ((childpid = fork()) == -1)
10
                break;
       return 0;
13
```

9. Monte a árvore de processos gerada com a execução do código a seguir (a figura 6 ilustra um exemplo de árvore de processos). [Faça o desenho em arquivo ou papel, e use o formulário online para fazer upload do seu arquivo ou scan do seu papel (PDF ou IMAGEM)]

```
c2 = 0;
1
        c1 = fork();
                                               /* fork number 1 */
2
        if (c1 == 0)
3
           c2 = fork();
                                               /* fork number 2 */
4
        fork();
                                                 fork number 3 */
        if (c2 > 0)
           fork();
                                               /* fork number 4 */
        exit();
```




Figura 6: Exemplo de árvore de processos

====== Exercícios de Consolidação ========

O objetivo desses exercícios é ajudar no estudo individual dos alunos. Soluções de questões específicas poderão ser discutidas em sala de aula, conforme interesse dos alunos.

- 1. Descreva o funcionamento da função fork(). Após o fork, como os processos pai e filho podem se comunicar/sincronizar (considere apenas as chamadas fork(), exec(), exit() e wait())?
- 2. Explique o que o código a seguir faz:

```
int main (int argc, char *argv[]) {
      pid_t childpid;
2
      int i, n;
3
      pid_t waitreturn;
      if (argc != 2){
                         /* check for number of command-line arguments
         fprintf(stderr, "Usage: %s processes\n", argv[0]);
         return 1;
7
8
      n = atoi(argv[1]);
9
      for (i = 1; i < n; i++)</pre>
10
         if (childpid = fork()) break;
11
      while (childpid != (waitreturn = wait(NULL)))
12
         if ((waitreturn == -1) && (errno != EINTR))
13
14
      fprintf(stderr, "I am process %ld, my parent is %ld\n",
15
                (long)getpid(),(long)getppid());
16
      return 0;
17
```

3. Implemente um programa C que possui uma variável do tipo array contendo 10 números desordenados. Esse processo MAIN deve criar um filho. Em seguida o MAIN deve ordenar o array usando "ordenação simples" enquanto o filho deve fazer "quick sort". Ao final da ordenação, cada processo deve exibir o tempo gasto para realizar a mesma. O processo que acabar primeiro deve finalizar (kill()) o seu "parente" e imprimir uma msg avisando sobre o "assassinato" (ex. "Sou o pai, matei meu filho!"). Observem que não deve ser possível que os dois processos mostrem as mensagens de assassinato.

23

```
Dicas:
  #include <sys/types.h>
  #include <signal.h>
2
  int kill(pid_t pid, int sig);
4
5
   - If pid is positive, then signal sig is sent to the process with
      the ID specified by pid.
   - SIGKILL and SIGINT are examples of signals that can cause the
      process to be terminated
   - Return Value: On success (at least one signal was sent), zero is
      returned. On error, -1 is returned, and errno is set
      appropriately.
9
  #include <time.h>
1
  clock_t c1, c2; /* variaveis que contam ciclos de processador */
4 float tmp;
  c1 = clock();
  //... codigo a ser executado
  c2 = clock();
   tmp = (c2-c1)*1000/CLOCKS_PER_SEC; //tempo de execucao em milisec.
  void quickSort(int valor[], int esquerda, int direita)
1
2
       int i, j, x, y;
3
       i = esquerda;
4
       j = direita;
5
       x = valor[(esquerda + direita) / 2];
       while(i <= j){
           while(valor[i] < x && i < direita){</pre>
8
                i++;
9
           }
10
           while(valor[j] > x && j > esquerda){
11
12
                j--;
           }
13
           if(i <= j){</pre>
               y = valor[i];
15
               valor[i] = valor[j];
16
               valor[j] = y;
17
               i++;
18
                j--;
19
           }
20
       }
21
       if(j > esquerda){
```

quickSort(valor, esquerda, j);

```
24     }
25     if(i < direita){
26         quickSort(valor, i, direita);
27     }
28 }</pre>
```